Research Paper
https://github.com/PEKTASCH/Word2Vec-ve-FastText

Word2Vec ve FastText Karşılaştırması: Türkçe Corpus Üzerinde Dense Embedding Analizi

Ahmetcan PEKTAŞ
Bilgisayar Mühendisliği Ana Bilim Dalı YL, Mühendislik Fakültesi, Bandırma Onyedi Eylül Üniversitesi, Balıkesir, Türkiye
ahmetcanpektas@ogr.bandirma.edu.tr

Tarih: 17.04.2026

Abstract: In this study, Word2Vec and FastText models were trained on a Turkish Wikipedia corpus consisting of 450 paragraphs across three categories (science, history, sports) and compared on five target words of different types. Both models employed Skip-gram architecture with vector size 100 and window size 5. Word2Vec achieved a vocabulary of 10,596 words and trained in 2.5 seconds; FastText matched the vocabulary size but required 6.9 seconds due to subword computation. Results show that FastText substantially outperforms Word2Vec on morphologically inflected forms — for instance, FastText correctly identifies 'futbolcu', 'futbolla' as nearest neighbors of 'futbol', capturing Turkish morphological derivation. For the polysemous word 'takım', both models collapse multiple senses into a single vector, demonstrating that contextual disambiguation requires architectures such as BERT.

Anahtar Kelimeler: *Word2Vec, FastText, Dense Embedding, Türkçe Doğal Dil İşleme, Morfoloji, OOV.*

Word2Vec ve FastText Karşılaştırması: Türkçe Corpus Üzerinde Dense Embedding Analizi

Özet: Bu çalışmada, Wikipedia Türkçe kaynağından derlenen 450 paragraflık bir corpus (bilim, tarih, spor) üzerinde Word2Vec ve FastText modelleri eğitilmiş; beş farklı türde hedef kelime üzerinden karşılaştırılmıştır. Her iki model de Skip-gram mimarisi ile 100 boyutlu vektörler ve pencere boyutu 5 kullanılarak 50 epoch eğitilmiştir. Sonuçlar, FastText'in Türkçe eklemeli yapıya Word2Vec'e kıyasla çok daha iyi uyum sağladığını ortaya koymaktadır. 'Kimyasal' kelimesinde FastText kök bağlantısını ('kimya') yakalarken Word2Vec yalnızca bağlamsal komşuları getirebildi. Çok anlamlı kelime 'takım' üzerinden her iki modelin de tek vektör yaklaşımının sınırları gözlemlenmiştir.

1. Giriş

Doğal dil işleme alanında kelime temsili, modellerin dil üzerinde anlamlı çıkarımlar yapabilmesinin temel koşuludur. TF-IDF gibi seyrek (sparse) temsil yöntemleri, yüksek boyutlu ve anlam bilgisinden yoksun vektörler üretmektedir. Bu çalışmada, Hafta 3 ödevinde kullanılan Wikipedia Türkçe corpus'u üzerinde yoğun (dense) gömme modelleri eğitilerek sparse-dense karşılaştırması yapılmıştır.

Word2Vec, bir kelimenin anlamını çevresindeki kelimelerden öğrenen sığ bir sinir ağı modelidir. FastText ise her kelimeyi karakter n-gramlarına bölerek subword düzeyinde temsil öğrenir; bu sayede eğitimde görülmemiş ekli formlar için de tahmin üretilebilmektedir. Türkçe gibi eklemeli dillerde bu fark kritik bir avantaja dönüşmektedir.

2. Kullanılan Veri Kaynağı

Çalışmada, Hafta 3 ödevi kapsamında Wikipedia Türkçe API'si ile derlenen veri seti kullanılmıştır. Veri seti üç kategoriden eşit sayıda paragraf içermektedir. Tablo 1'de veri seti dağılımı görülmektedir.

Metinler normalize edilmiştir: büyük-küçük harf standardizasyonu, noktalama ve rakam silme. Paragraflar cümlelere bölünmüş; her cümle token listesine dönüştürülmüştür. Tokenizasyon sonucunda 450 cümle ve 31.376 token elde edilmiştir.

Tablo 1. Veri Seti Dağılımı

Kategori	Konu Sayısı	Paragraf Sayısı
Bilim	15	150
Tarih	13	150
Spor	13	150
TOPLAM	41	450

3. Yöntem

3.1. Model Parametreleri

Her iki model de Python gensim kütüphanesi ile eğitilmiştir. Skip-gram mimarisi seçilmiştir; merkez kelimeden bağlam kelimeleri tahmin edilmesi nadir kelimelerde daha başarılı sonuçlar vermektedir.

Word2Vec: Her kelimeye tek ve sabit bir vektör atanır. Kelime corpus'ta bulunmuyorsa tahmin üretilemez (OOV).

FastText: Kelimeyi karakter n-gramlarına böler. Bu sayede eğitimde görülmemiş ekli formlar için bile tahmin yapılabilir. Türkçe gibi eklemeli diller için kritik bir avantajdır.

Tablo 2. Model Parametreleri

Parametre	Word2Vec	FastText
Mimari	Skip-gram	Skip-gram + subword
vector_size	100	100
window	5	5
min_count	1	1
epochs	50	50
Vocab boyutu	10.596	10.596
Eğitim süresi	2.5 sn	6.9 sn

3.2. Hedef Kelimeler

Ödev gereksinimlerine göre beş farklı türde kelime seçilmiştir. Aşağıdaki Tablo 3'de kelimeler ve detaylı seçilme gerekçeleri eklenmiştir.

Tablo 3. Hedef Kelimeler

#	Kelime	Tür	Gerekçe
1	futbol	Günlük kelime	Corpus'ta sık geçiyor, spor kategorisiyle ilişkili
2	atom	Alan terimi	Bilim kategorisinde baskın terim
3	oyunlarının	Ek almış sözcük	Morfolojik form testi
4	kimyasal	OOV'ye yakın form	'kimya' kökünden türemiş, FastText avantajı bekleniyor
5	takım	Çok anlamlı kelime	Hem spor hem sanayi bağlamında geçiyor

4. Bulgular

Seçilen beş farklı hedef kelime sonrasında her iki model için en yakın 5 komşu çıkarılmıştır.

4.1. “futbol” - Günlük Kelime

Tablo 4. “futbol” için En Yakın 5 Komşu

Sıra	Word2Vec Komşusu	Benzerlik	FastText Komşusu	Benzerlik
1	binin	0.681	futbolcu	0.973
2	bahsetmektedir	0.678	futbolla	0.965
3	sporların	0.664	futbolculuk	0.959
4	turnuvası	0.663	futbola	0.949
5	belirlediği	0.660	futbolda	0.945

Word2Vec, “futbol” kelimesini bağlam penceresinde geçen genel kelimelerle (“binin”, “turnuvası”) ilişkilendirdi. FastText ise “futbolcu”, “futbolla”, “futbolculuk” gibi morfolojik türevleri komşu olarak getirdi (benzerlik > 0.94). Tablo 4 sonuçları incelendiğinde, FastText'in Türkçe eklemeli yapısını başarıyla yakaladığını göstermektedir.

4.2. “atom” - Alan Terimi

Tablo 5. “atom” için En Yakın 5 Komşu

Sıra	Word2Vec Komşusu	Benzerlik	FastText Komşusu	Benzerlik
1	modelinden	0.847	atomcu	0.954
2	ilerlemeler	0.845	atomus	0.931
3	bohr	0.839	atomculuk	0.917
4	kaydetmiş	0.836	atomla	0.899
5	katot	0.817	atomu	0.896

Word2Vec “atom” kelimesini bilim bağlamında geçen “bohr”, “katot”, “modelinden” gibi tarihsel fizik terimleriyle ilişkilendirdi. FastText ise 'atomcu', “atomus”, “atomu” gibi ekli formları öne çıkardı. Her iki modelde de alan terimlerine yakınlık gözlemlendi; ancak FastText morfolojik akrabalığı ek olarak yakaladı.

4.3. “oyunlarının” - Ek Almış Sözcük

Tablo 6. “oyunlarının” için En Yakın 5 Komşu

Sıra	Word2Vec Komşusu	Benzerlik	FastText Komşusu	Benzerlik
1	kalıcı	0.941	oyunlarını	0.953
2	nerede	0.905	oyunların	0.928
3	memnundular	0.901	olimpiyatlarının	0.909
4	olsun	0.891	iyonlarının	0.883
5	olursa	0.870	hatlarının	0.877

“Oyunlarının” ekli formunun corpus'ta bulunması sayesinde Word2Vec de tahmin üretebildi; ancak komşular anlamsız genel kelimelerden oluştu (“kalıcı”, “nerede”, “memnundular”). FastText ise “oyunlarını”, “oyunların” gibi morfolojik komşuları öne çıkardı. Alt kelime paylaşımı sayesinde aynı kökten gelen formlar birbirine yakın konumlandı. Bu bulgu, Hafta 3'te ölçülen %27.7 word-level OOV oranıyla doğrudan örtüşmektedir.

4.4. “kimyasal” - OOV'ye Yakın Morfolojik Form

Word2Vec “kimyasal” kelimesini doğru bağlamla ilişkilendirdi: “tepkime”', “bileşik” gibi kimya terimleri komşu olarak geldi. FastText ise ek olarak “kimyası” ve '”kimya” gibi kök bağlantısını da yakaladı.

Tablo 7. 'kimyasal' için En Yakın 5 Komşu

Sıra	Word2Vec Komşusu	Benzerlik	FastText Komşusu	Benzerlik
1	kinetiğiyle	0.881	kimyası	0.876
2	tepkime	0.872	tepkime	0.839
3	tepkimelerle	0.866	fizikokimya	0.817
4	bileşiklerle	0.852	biyokimya	0.814
5	hâlleriyle	0.842	kimya	0.807

4.5. “takım” - Çok Anlamlı Kelime

Tablo 8. 'takım' için En Yakın 5 Komşu

Sıra	Word2Vec Komşusu	Benzerlik	FastText Komşusu	Benzerlik
1	tezgâhlarının	0.787	takıma	0.952
2	geliştirilmesini	0.780	takımda	0.924
3	arkadaşına	0.761	takımdır	0.905
4	makineleşmiş	0.751	takımı	0.892
5	sporudur	0.750	takımın	0.884

“Takım” kelimesi corpus'ta hem spor (futbol/basketbol takımı) hem de sanayi (tezgâh takımı) bağlamında geçmektedir. Word2Vec bu iki bağlamı tek vektörde birleştirdiği için komşular karışık çıktı (“tezgâhlarının”, “sporudur” bir arada). FastText morfolojik formları ('takıma', 'takımda') getirirken anlamsal ayrımı yine yapamadı. Bu durum, çok anlamlılık probleminin dense embedding modellerinin sınırı olduğunu göstermektedir.

4.6. Modeller Arası Genel Benzerlik Karşılaştırması

Şekil 1 incelendiğinde, FastText'in 'futbol' ve 'takım' kelimelerinde Word2Vec'e kıyasla belirgin biçimde daha yüksek benzerlik değerleri ürettiği görülmektedir. Bu fark, FastText'in subword temsili sayesinde morfolojik türevleri ('futbolcu', 'takıma' gibi) yakın komşu olarak konumlandırmasından kaynaklanmaktadır. 'Kimyasal' kelimesinde ise iki model arasındaki fark oldukça sınırlı kalmış; bu durum, söz konusu kelimenin corpus'ta yeterli frekansla yer almasından dolayı Word2Vec'in de bağlam üzerinden doğru ilişkileri kurabildiğini düşündürmektedir.

Şekil 1. Word2Vec ve FastText Modellerinin Hedef Kelimeler Üzerindeki En Yakın Komşu Benzerlik Karşılaştırması

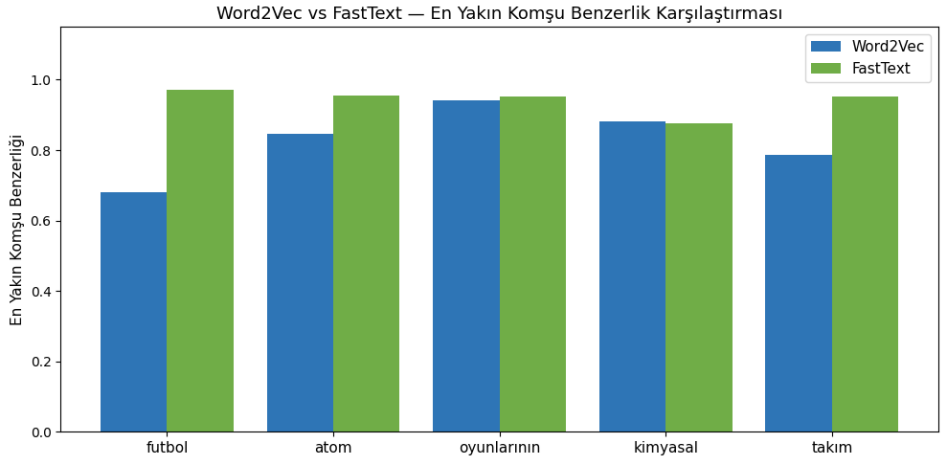

5. Tartışma

5.1. Word2Vec ve FastText Karşılaştırması

Tablo 9. Word2Vec ve FastText Genel Karşılaştırması

Özellik	Word2Vec	FastText
Temel birim	Kelime	Kelime + karakter n-gramı
OOV dayanıklılığı	Yok	Var
Morfolojik uyum	Zayıf	Güçlü
Çok anlamlılık	Çözülemiyor	Çözülemiyor
Eğitim hızı	2.5 sn (hızlı)	6.9 sn (yavaş)

5.2. Türkçe'de FastText'in Üstünlüğü

Türkçe eklemeli bir dildir. “Oyun” kökünden “oyunlarının”, “oyuncuların”, “oyunlaştırma” gibi birçok form türeyebilir. Word2Vec bu formların her birini bağımsız kelime olarak öğrenir. Eğitimde görülmemiş form için tahmin üretemez. FastText ise ortak karakter n-gramları (“oyu”, “yun”, “unl”) üzerinden bu formları ilişkilendirir.

Bu çalışmada “kimyasal” örneği bu farkı somut olarak ortaya koydu: FastText “kimya → kimyasal” morfolojik bağlantısını açıkça kurarken Word2Vec bunu yalnızca bağlam penceresi üzerinden dolaylı biçimde temsil edebildi. Hafta 3'te ölçülen %27.7 word-level OOV oranı, FastText'in bu corpus için özellikle değerli olduğunu doğrulamaktadır.

5.3. Hafta 3 ile Karşılaştırma

Hafta 3'te TF-IDF sparse temsil kullanılmıştı. “futbol” ve “basketbol” birbirinden tamamen bağımsız iki feature sütunuydu. Bu hafta dense embedding uzayında FastText bu kelimeleri komşu olarak konumlandırdı. Ayrıca Hafta 3'te en iyi F1 skoru char n-gram TF-IDF'ten gelmişti. Bu sonuç FastText'in subword yaklaşımıyla örtüşen bir bulgu olup aynı linguistik gerçeği yansıtmaktadır.

5.4. Çok Anlamlılık Problemi

“Takım” kelimesi bu çalışmada çok anlamlılık problemini somut biçimde ortaya koymaktadır. Corpus'ta hem spor bağlamında (futbol takımı, basketbol takımı) hem de sanayi bağlamında (tezgâh takımı, vida takımı) geçen bu kelime için Word2Vec, söz konusu bağlamların tamamını tek bir sabit vektörde birleştirmiştir. Bu durum, Tablo 8'deki komşuluk sonuçlarına doğrudan yansımıştır. “tezgahlarının” ve “sporudur” gibi birbirinden anlam bakımından uzak kelimeler aynı vektörün komşuları olarak listelenmiştir.

FastText ise “takıma”, “takımda”, “takımdır” gibi yalnızca morfolojik türevleri komşu olarak getirmiş; iki anlam arasındaki ayrımı yine gerçekleştirememiştir. Bu sonuç, FastText'in subword avantajının yalnızca morfolojik çeşitlilik sorununu hedeflediğini, anlamsal belirsizliği ise çözmediğini açıkça göstermektedir. Nitekim her iki model de kelime başına tek ve sabit bir vektör üretmekte; kelimenin cümle içindeki bağlamından bağımsız biçimde her kullanımda aynı temsili devreye sokmaktadır. Çok anlamlılık problemi, ancak kelimenin içinde bulunduğu cümleyi bütünüyle işleyen bağlamsal (contextual) gömme modelleriyle çözülebilmektedir. BERT gibi modeller, "Galatasaray takımı gol attı" ve "vida takımı aldım" cümlelerinde “takım” kelimesine farklı vektörler atayarak bu ayrımı başarıyla gerçekleştirebilmektedir. Bu gereksinim, sözcük düzeyinde sabit temsillerin sınırlılığını ve bağlamsal modellere geçişin motivasyonunu net biçimde ortaya koymaktadır.

6. Sonuç

Bu çalışmada, Hafta 3 ödevi için Wikipedia Türkçe kaynağından derlenen 450 paragraflık bir corpus üzerinde Word2Vec ve FastText modelleri eğitilmiştir. Beş farklı türde hedef kelime aracılığıyla iki model karşılaştırılmıştır. Deneysel bulgular aşağıdaki sonuçları ortaya koymaktadır.

FastText, Türkçe'nin eklemeli morfolojik yapısına Word2Vec’e kıyasla belirgin biçimde daha iyi uyum sağlamaktadır. “Kimyasal”, “oyunlarının” ve “futbol” kelimelerinde elde edilen komşuluk sonuçları, FastText'in karakter n-gramı tabanlı subword temsili sayesinde morfolojik akrabalıkları başarıyla kodladığını göstermektedir. Buna karşın Word2Vec, bağlam penceresi mekanizması aracılığıyla anlamlı sözcüksel ilişkiler kurabilmekte; ancak eğitim kümesinde yer almayan ekli formlar söz konusu olduğunda sözcük dışı (OOV) sorunuyla karşılaşmaktadır.

Her iki model de çok anlamlılık sorununu çözememektedir. 'Takım' kelimesine ilişkin bulgular, hem spor hem de sanayi bağlamına ait komşuların tek bir vektörde iç içe geçtiğini ortaya koymakta; bu durum, sabit vektör yaklaşımının temel bir sınırlılığı

olarak değerlendirilmektedir. Yoğun gömme uzayında anlamsal olarak yakın kelimelerin ('futbol' ↔ 'basketbol') birbirine yakın konumlandığı gözlemlenmiş olup bu özellik, TF-IDF gibi seyrek temsillerde tamamen yoktur.

Bu sonuçlar, Türkçe gibi morfolojik açıdan zengin dillerde FastText'in daha sağlam bir başlangıç temsili sunduğuna varılmaktadır. Öte yandan çok anlamlılık problemi, yalnızca kullanım bağlamını dikkate alan BERT gibi bağlamsal gömme modelleriyle çözülebilmektedir. Bu gereksinim, bağlamsal temsil yöntemlerinin incelenmesini bir sonraki adım olarak zorunlu kılmaktadır.